

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

23TNT1

Bài tập khai thác mẫu

Đề tài: Khai thác dữ liệu và ứng dụng

Môn học: Khai thác dữ liệu và ứng dụng

Sinh viên thực hiện:

23122006 - Lưu Thượng Hồng

Giáo viên hướng dẫn:

GS.TS. Lê Hoài Bắc

ThS. Lê Nhật Nam

Ngày 3 tháng 5 năm 2026



Mục lục

Câu 4.1	1
Câu 4.2	1
Câu 4.3	2
Câu 4.4	5
Câu 4.5	6
Câu 4.6	7
Câu 4.8	7
Câu 4.9	8
Câu 4.10	8
Câu 4.11	9
Câu 4.13	9
Câu 4.14	9

Câu 4.1

Suppose you have the set $\mathcal{C}$ of all frequent closed itemsets on a data set $\mathcal{D}$, as well as the support count for each frequent closed itemset. Describe an algorithm to determine whether a given itemset $\mathcal{X}$ is frequent or not, and the support of $\mathcal{X}$ if it is frequent.

Lời giải

Itemset $\mathcal{X}$ là phổ biến khi và chỉ khi itemset $\mathcal{X}$ là một tập con của một itemset phổ biến đóng $\mathcal{Y} \in \mathcal{C}$, và $\text{sup}(\mathcal{X}) = \max\{\text{sup}(\mathcal{Y}) \mid \mathcal{Y} \in \mathcal{C}, \mathcal{X} \subseteq \mathcal{Y}\}$.

Thuật toán:

Algorithm 1 Kiểm tra tính phổ biến của tập $\mathcal{X}$

Require: $\mathcal{C}$, sup_of_sets , X

- 1: $\text{sup_X} \leftarrow \max(\{\text{sup_of_sets}[Y] \mid Y \in \mathcal{C}, X \subseteq Y\} \cup \{0\})$
 - 2: **if** $\text{sup_X} > 0$ **then**
 - 3: **return** “Frequent”, sup_X
 - 4: **else**
 - 5: **return** “Not frequent”
 - 6: **end if**
-

Câu 4.2

An itemset $\mathcal{X}$ is called a generator on a data set $\mathcal{D}$ if there does not exist a proper subitemset $\mathcal{Y} \subset \mathcal{X}$ such that $\text{sup}(\mathcal{X}) = \text{sup}(\mathcal{Y})$. A generator $\mathcal{X}$ is a frequent generator if $\text{sup}(\mathcal{X})$ passes the minimum support threshold. Let $\mathcal{G}$ be the set of all frequent generators on a data set $\mathcal{D}$.

- a. Can you determine whether an itemset $\mathcal{A}$ is frequent and the support of $\mathcal{A}$, if it is frequent, using only $\mathcal{G}$ and the support counts of all frequent generators? If yes, present your algorithm. Otherwise, what other information is needed? Can you give an algorithm assuming the information needed is available?
- b. What is the relationship between closed itemsets and generators?

Lời giải

a.

Không thể xác định itemset $\mathcal{A}$ là phổ biến và support của $\mathcal{A}$ chỉ dựa trên tập $\mathcal{G}$ và support của các tập phổ biến sinh, vì có thể tồn tại itemset $\mathcal{X}$ không phải là tập sinh nhưng có cùng support với một tập sinh khác nên thông tin về itemset đó không xuất hiện trong $\mathcal{G}$

Ví dụ:

$$\text{sup}(\{A\}) = \text{sup}(\{A, B\})$$

thì $\{A, B\}$ không phải tập sinh, nên thông tin về $\{A, B\}$ không xuất hiện trong $\mathcal{G}$.

Do đó cần thêm:

- Tập phổ biến đóng $\mathcal{C}$,
- Support của từng tập đóng trong $\mathcal{C}$.

Khi đó thuật toán kiểm tra tính phổ biến của tập $\mathcal{A}$ sẽ giống như thuật toán [1](#).

b.

Với mỗi itemset phổ biến X , gọi $C(X)$ là tập đóng tương ứng và $G(X)$ là tập các tập sinh của lớp tương đương chứa X . Ta luôn có:

1. $\forall g \in G(X) : g \subseteq X \subseteq C(X)$.
2. $\text{sup}(g) = \text{sup}(X) = \text{sup}(C(X))$.

Câu 4.3

The Apriori algorithm makes use of prior knowledge of subset support properties.

- a. Prove that all nonempty subsets of a frequent itemset must also be frequent.
- b. Prove that the support of any nonempty subset s' of itemset s must be at least as great as the support of s .
- c. Given frequent itemset l and subset s of l , prove that the confidence of the rule “ $s' \Rightarrow (l - s')$ ” cannot be more than the confidence of “ $s \Rightarrow (l - s)$ ”, where s' is a subset of s .

- d. A partitioning variation of Apriori subdivides the transactions of a database $\mathcal{D}$ into n nonoverlapping partitions. Prove that any itemset that is frequent in $\mathcal{D}$ must be frequent in at least one partition of $\mathcal{D}$.

Lời giải

a.

Gọi X là một itemset phổ biến:

$$\text{sup}(X) \geq \text{minsup}$$

Với mọi tập con khác rỗng $Y \subseteq X$, mọi transaction chứa X đều chứa Y . Do đó:

$$T(X) \subseteq T(Y) \implies \text{sup}(Y) \geq \text{sup}(X)$$

Vì:

$$\text{sup}(X) \geq \text{minsup} \implies \text{sup}(Y) \geq \text{minsup}$$

Do đó mọi tập con khác rỗng của một itemset phổ biến cũng là phổ biến.

b.

Cho $s' \subseteq s$.

Mọi transaction chứa s đều chứa s' , nên $T(s) \subseteq T(s')$

Suy ra:

$$|T(s)| \leq |T(s')|$$

Do đó $\text{sup}(s) \leq \text{sup}(s')$, hay $\text{sup}(s') \geq \text{sup}(s)$

c.

Confidence của luật $s \Rightarrow (l - s)$ là:

$$\text{conf}(s \Rightarrow (l - s)) = \frac{\text{sup}(l)}{\text{sup}(s)}$$

Tương tự:

$$\text{conf}(s' \Rightarrow (l - s')) = \frac{\text{sup}(l)}{\text{sup}(s')}$$

Vì $s' \subseteq s$, nên theo câu b: $\text{sup}(s') \geq \text{sup}(s)$

Suy ra:

$$\frac{\sup(l)}{\sup(s')} \leq \frac{\sup(l)}{\sup(s)}$$

Do đó:

$$\text{conf}(s' \Rightarrow (l - s')) \leq \text{conf}(s \Rightarrow (l - s))$$

d.

Giả sử CSDL $\mathcal{D}$ được chia thành n partition không giao nhau:

$$\mathcal{D} = D_1 \cup D_2 \cup \dots \cup D_n$$

Gọi X là một itemset phổ biến trong $\mathcal{D}$:

$$\sup_{\mathcal{D}}(X) \geq \text{minsup}$$

Giả sử phản chứng rằng X không phổ biến trong mọi partition. Khi đó:

$$\sup_{D_i}(X) < \text{minsup} \quad \forall i = \overline{1, n}$$

Do support toàn cục bằng tổng support trên các partition:

$$\sup_{\mathcal{D}}(X) = \sum_{i=1}^n \sup_{D_i}(X) \implies \sup_{\mathcal{D}}(X) < \sum_{i=1}^n \text{minsup}$$

Mâu thuẫn với giả thiết rằng X phổ biến trong $\mathcal{D}$.

Do đó phải tồn tại ít nhất một partition D_i sao cho:

$$\sup_{D_i}(X) \geq \text{minsup}$$

Tức là X phổ biến trong ít nhất một partition.

Câu 4.4

Let c be a candidate itemset in C_k generated by the Apriori algorithm. How many length- $(k - 1)$ subsets do we need to check in the prune step? Per your previous answer, can you give an improved version of procedure `has_infrequent_subset` in Fig. 4.4?

Lời giải

Cho candidate itemset:

$$c = \{i_1, i_2, \dots, i_k\} \in C_k$$

Trong bước prune của Apriori, về lý thuyết cần kiểm tra tất cả các tập con độ dài $(k - 1)$ của c để bảo đảm rằng chúng đều thuộc L_{k-1} .

Số lượng tập con độ dài $(k - 1)$ của một tập gồm k phần tử là:

$$\binom{k}{k-1} = k$$

Tuy nhiên, do c được sinh ra bằng phép self-join từ hai itemset phổ biến thuộc L_{k-1} , nên chỉ cần kiểm tra các tập con còn lại của c (trừ 2 tập con tạo nên c).

Cụ thể, giả sử:

$$c = l_1 \cup l_2$$

với:

$$l_1 = \{i_1, \dots, i_{k-2}, i_{k-1}\}$$

$$l_2 = \{i_1, \dots, i_{k-2}, i_k\}$$

Hai tập con $c - \{i_{k-1}\} = l_2$ và $c - \{i_k\} = l_1$ đã chắc chắn phổ biến vì thuộc L_{k-1} .

Do đó chỉ cần kiểm tra các tập con còn lại, tức $k - 2$ tập con.

Phiên bản cải tiến của thủ tục `has_infrequent_subset`:

Algorithm 2 Cải tiến has_infrequent_subset

Require: Candidate $c = \{i_1, i_2, \dots, i_k\}$, frequent itemsets L_{k-1}

Ensure: TRUE if c has an infrequent subset

```

1: for  $j = 1$  to  $k - 2$  do
2:    $s \leftarrow c - \{i_j\}$ 
3:   if  $s \notin L_{k-1}$  then
4:     return TRUE
5:   end if
6: end for
7: return FALSE

```

Câu 4.5

Section 4.2.2 describes a method for generating association rules from frequent itemsets. Propose a more efficient method. Explain why it is more efficient than the one proposed there. (Hint: consider incorporating the properties of Exercises 4.3(b), (c) into your design.)

Lời giải

Sử dụng tính chất pruning của confidence:

- Nếu một luật $s \Rightarrow (l - s)$ không đạt $minconf$, thì mọi luật tạo từ các tập con của s cũng sẽ không đạt $minconf$.
- Vì vậy, ta không cần sinh toàn bộ các tập con của l .

Algorithm 3 Cải tiến thuật toán sinh luật kết hợp

Require: Frequent itemset l , minimum confidence $minconf$

```

1: for all nonempty subsets  $s \subset l$  do
2:    $conf \leftarrow \frac{support(l)}{support(s)}$ 
3:   if  $conf \geq minconf$  then
4:     Output rule:


$s \Rightarrow (l - s)$


5:     Continue exploring subsets of  $s$ 
6:   else
7:     Prune all subsets of  $s$ 
8:   end if
9: end for

```

Phương pháp này hiệu quả hơn vì nó loại bỏ sớm các tập ứng viên không thể tạo ra luật mạnh. Nếu một luật không đạt *minconf*, mọi mở rộng của nó cũng không cần xét tiếp. Do đó, số lượng tập con cần sinh và kiểm tra giảm đáng kể so với cách brute-force sinh toàn bộ $2^{|I|} - 2$ tập con.

Câu 4.6

A database has five transactions. Let *min_sup* = 60% and *min_conf* = 80%.

TID	items_bought
T100	{M, O, N, K, E, Y}
T200	{D, O, N, K, E, Y}
T300	{M, A, K, E}
T400	{M, U, C, K, Y}
T500	{C, O, K, I, E}

- Find all frequent itemsets using Apriori and FP-growth, respectively. Compare the efficiency of the two mining processes.
- List all the strong association rules (with support *s* and confidence *c*) matching the following metarule, where *X* is a variable representing customers, and *item_i* denotes variables representing items:

$$\forall x \in transaction, buys(X, item_1) \wedge buys(X, item_2) \\ \Rightarrow buys(X, item_3) \quad [s, c]$$

Lời giải

Câu 4.8

A database has four transactions. Let *min_sup* = 60% and *min_conf* = 80%.

cust_ID	TID	items_bought (in the form of brand-item_category)
01	T100	{King's-Crab, Sunset-Milk, Dairyland-Cheese, Best-Bread}
02	T200	{Best-Cheese, Dairyland-Milk, Goldenfarm-Apple, Tasty-Pie, Wonder-Bread}
01	T300	{Westcoast-Apple, Dairyland-Milk, Wonder-Bread, Tasty-Pie}
03	T400	{Wonder-Bread, Sunset-Milk, Dairyland-Cheese}

- a. At the granularity of item_category (e.g., $item_i$ could be “Milk”), for the rule template,

$$\begin{aligned} \forall X \in transaction, buys(X, item_1) \wedge buys(X, item_2) \\ \Rightarrow buys(X, item_3) \quad [s, c], \end{aligned}$$

list the frequent k -itemset for the largest k , and all the strong association rules (with their support s and confidence c) containing the frequent k -itemset for the largest k .

- b. At the granularity of brand-item_category (e.g., $item_i$ could be “Sunset-Milk”), for the rule template,

$$\forall X \in customer, buys(X, item_1) \wedge buys(X, item_2) \Rightarrow buys(X, item_3),$$

list the frequent k -itemset for the largest k (but do not print any rules).

Lời giải

Câu 4.9

Suppose that a large store has a transactional database that is distributed among four locations. Transactions in each component database have the same format, namely $T_j : \{i_1, \dots, i_m\}$, where T_j is a transaction identifier, and i_k ($1 \leq k \leq m$) is the identifier of an item purchased in the transaction. Propose an efficient algorithm to mine global association rules. Your algorithm should not require shipping all the data to one site and should not cause excessive network communication overhead.

Lời giải

Câu 4.10

Suppose that frequent itemsets are saved for a large transactional database, DB . Discuss how to efficiently mine the (global) association rules under the same minimum support threshold, if a set of new transactions, denoted as ΔDB , is (incrementally) added in.

Lời giải

Câu 4.11

Most frequent pattern mining algorithms consider only distinct items in a transaction. However, multiple occurrences of an item in the same shopping basket, such as four cakes and three jugs of milk, can be important in transactional data analysis. How can one mine frequent itemsets efficiently considering multiple occurrences of items? Propose modifications to the well-known algorithms, such as Apriori and FP-growth, to adapt to such a situation.

Lời giải

Câu 4.13

Give a short example to show that items in a strong association rule actually may be negatively correlated.

Lời giải

Câu 4.14

The following contingency table summarizes supermarket transaction data, where *hot dogs* refers to the transactions containing hot dogs, $\overline{hot\ dogs}$ refers to the transactions that do not contain hot dogs, *hamburgers* refers to the transactions containing hamburgers, and $\overline{hamburgers}$ refers to the transactions that do not contain hamburgers.

	<i>hot dogs</i>	$\overline{hot\ dogs}$	Σ_{row}
<i>hamburgers</i>	2000	500	2500
$\overline{hamburgers}$	1000	1500	2500
Σ_{col}	3000	2000	5000

- Suppose that the association rule “*hot dogs* $\Rightarrow$ *hamburgers*” is mined. Given a minimum support threshold of 25% and a minimum confidence threshold of 50%, is this association rule strong?

- b. Based on the given data, is the purchase of hot dogs independent of the purchase of hamburgers? If not, what kind of correlation relationship exists between the two?
- c. Compare the use of the all_confidence, max_confidence, Kulczynski, and cosine measures with lift and correlation on the given data.

Lời giải