

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

23TNT1

Bài tập khai thác mẫu

Đề tài: Khai thác dữ liệu và ứng dụng

Môn học: Khai thác dữ liệu và ứng dụng

Sinh viên thực hiện:

23122006 - Lưu Thượng Hồng

Giáo viên hướng dẫn:

GS.TS. Lê Hoài Bắc

ThS. Lê Nhật Nam

Ngày 3 tháng 5 năm 2026



Mục lục

Câu 4.1	1
Câu 4.2	1
Câu 4.3	2
Câu 4.4	5
Câu 4.5	6
Câu 4.6	7
Câu 4.8	10
Câu 4.9	12
Câu 4.10	13
Câu 4.11	13
Câu 4.13	14
Câu 4.14	15

Câu 4.1

Suppose you have the set $\mathcal{C}$ of all frequent closed itemsets on a data set $\mathcal{D}$, as well as the support count for each frequent closed itemset. Describe an algorithm to determine whether a given itemset $\mathcal{X}$ is frequent or not, and the support of $\mathcal{X}$ if it is frequent.

Lời giải Itemset $\mathcal{X}$ là phổ biến khi và chỉ khi itemset $\mathcal{X}$ là một tập con của một itemset phổ biến đóng $\mathcal{Y} \in \mathcal{C}$, và $\text{sup}(\mathcal{X}) = \max\{\text{sup}(\mathcal{Y}) \mid \mathcal{Y} \in \mathcal{C}, \mathcal{X} \subseteq \mathcal{Y}\}$.

Thuật toán:

Algorithm 1 Kiểm tra tính phổ biến của tập $\mathcal{X}$

Require: $\mathcal{C}$, sup_of_sets , X

```

1:  $\text{sup\_X} \leftarrow \max(\{\text{sup\_of\_sets}[Y] \mid Y \in \mathcal{C}, X \subseteq Y\} \cup \{0\})$ 
2: if  $\text{sup\_X} > 0$  then
3:   return “Phổ biến”,  $\text{sup\_X}$ 
4: else
5:   return “Không phổ biến”
6: end if
```

Câu 4.2

An itemset $\mathcal{X}$ is called a generator on a data set $\mathcal{D}$ if there does not exist a proper subitemset $\mathcal{Y} \subset \mathcal{X}$ such that $\text{sup}(\mathcal{X}) = \text{sup}(\mathcal{Y})$. A generator $\mathcal{X}$ is a frequent generator if $\text{sup}(\mathcal{X})$ passes the minimum support threshold. Let $\mathcal{G}$ be the set of all frequent generators on a data set $\mathcal{D}$.

- a. Can you determine whether an itemset $\mathcal{A}$ is frequent and the support of $\mathcal{A}$, if it is frequent, using only $\mathcal{G}$ and the support counts of all frequent generators? If yes, present your algorithm. Otherwise, what other information is needed? Can you give an algorithm assuming the information needed is available?
- b. What is the relationship between closed itemsets and generators?

Lời giải a.

Không thể xác định itemset $\mathcal{A}$ là phổ biến và support của $\mathcal{A}$ chỉ dựa trên tập $\mathcal{G}$ và support của các tập phổ biến sinh, vì có thể tồn tại itemset $\mathcal{X}$ không phải là tập sinh nhưng có cùng support với một tập sinh khác nên thông tin về itemset đó không xuất hiện trong $\mathcal{G}$

Ví dụ:

$$\text{sup}(\{A\}) = \text{sup}(\{A, B\})$$

thì $\{A, B\}$ không phải tập sinh, nên thông tin về $\{A, B\}$ không xuất hiện trong $\mathcal{G}$.

Do đó cần thêm:

- Tập phổ biến đóng $\mathcal{C}$,
- Support của từng tập đóng trong $\mathcal{C}$.

Khi đó thuật toán kiểm tra tính phổ biến của tập $\mathcal{A}$ sẽ giống như thuật toán [1](#).

b.

Với mỗi itemset phổ biến X , gọi $C(X)$ là tập đóng tương ứng và $G(X)$ là tập các tập sinh của lớp tương đương chứa X . Ta luôn có:

1. $\forall g \in G(X) : g \subseteq X \subseteq C(X)$.
2. $\text{sup}(g) = \text{sup}(X) = \text{sup}(C(X))$.

Câu 4.3

The Apriori algorithm makes use of prior knowledge of subset support properties.

- a. Prove that all nonempty subsets of a frequent itemset must also be frequent.
- b. Prove that the support of any nonempty subset s' of itemset s must be at least as great as the support of s .
- c. Given frequent itemset l and subset s of l , prove that the confidence of the rule “ $s' \Rightarrow (l - s')$ ” cannot be more than the confidence of “ $s \Rightarrow (l - s)$ ”, where s' is a subset of s .

- d. A partitioning variation of Apriori subdivides the transactions of a database $\mathcal{D}$ into n nonoverlapping partitions. Prove that any itemset that is frequent in $\mathcal{D}$ must be frequent in at least one partition of $\mathcal{D}$.

Lời giải a.

Gọi X là một itemset phổ biến:

$$\text{sup}(X) \geq \text{minsup}$$

Với mọi tập con khác rỗng $Y \subseteq X$, mọi transaction chứa X đều chứa Y . Do đó:

$$T(X) \subseteq T(Y) \implies \text{sup}(Y) \geq \text{sup}(X)$$

Vì:

$$\text{sup}(X) \geq \text{minsup} \implies \text{sup}(Y) \geq \text{minsup}$$

Do đó mọi tập con khác rỗng của một itemset phổ biến cũng là phổ biến.

b.

Cho $s' \subseteq s$.

Mọi transaction chứa s đều chứa s' , nên $T(s) \subseteq T(s')$

Suy ra:

$$|T(s)| \leq |T(s')|$$

Do đó $\text{sup}(s) \leq \text{sup}(s')$, hay $\text{sup}(s') \geq \text{sup}(s)$

c.

Confidence của luật $s \Rightarrow (l - s)$ là:

$$\text{conf}(s \Rightarrow (l - s)) = \frac{\text{sup}(l)}{\text{sup}(s)}$$

Tương tự:

$$\text{conf}(s' \Rightarrow (l - s')) = \frac{\text{sup}(l)}{\text{sup}(s')}$$

Vì $s' \subseteq s$, nên theo câu b: $\text{sup}(s') \geq \text{sup}(s)$

Suy ra:

$$\frac{\sup(l)}{\sup(s')} \leq \frac{\sup(l)}{\sup(s)}$$

Do đó:

$$\text{conf}(s' \Rightarrow (l - s')) \leq \text{conf}(s \Rightarrow (l - s))$$

d.

Giả sử CSDL $\mathcal{D}$ được chia thành n partition không giao nhau:

$$\mathcal{D} = D_1 \cup D_2 \cup \dots \cup D_n$$

Gọi X là một itemset phổ biến trong $\mathcal{D}$. Ký hiệu $\text{count}_{\mathcal{D}}(X)$ là số transaction trong $\mathcal{D}$ chứa X . Khi đó:

$$\text{count}_{\mathcal{D}}(X) \geq \text{minsup} \cdot |\mathcal{D}|$$

Giả sử phản chứng rằng X không phổ biến trong mọi partition. Khi đó:

$$\text{count}_{D_i}(X) < \text{minsup} \cdot |D_i| \quad \forall i = \overline{1, n}$$

Vì các partition không giao nhau, tổng số lần xuất hiện của X trên toàn bộ CSDL bằng tổng số lần xuất hiện trên từng partition:

$$\text{count}_{\mathcal{D}}(X) = \sum_{i=1}^n \text{count}_{D_i}(X) \implies \text{count}_{\mathcal{D}}(X) < \sum_{i=1}^n \text{minsup} \cdot |D_i| = \text{minsup} \cdot \sum_{i=1}^n |D_i| = \text{minsup} \cdot |\mathcal{D}|$$

Mâu thuẫn với giả thiết rằng X phổ biến trong $\mathcal{D}$.

Do đó phải tồn tại ít nhất một partition D_i sao cho:

$$\text{count}_{D_i}(X) \geq \text{minsup} \cdot |D_i|$$

Tức là X phổ biến trong ít nhất một partition.

Câu 4.4

Let c be a candidate itemset in C_k generated by the Apriori algorithm. How many length- $(k-1)$ subsets do we need to check in the prune step? Per your previous answer, can you give an improved version of procedure `has_infrequent_subset` in Fig. 4.4?

Lời giải Cho candidate itemset:

$$c = \{i_1, i_2, \dots, i_k\} \in C_k$$

Trong bước prune của Apriori, về lý thuyết cần kiểm tra tất cả các tập con độ dài $(k-1)$ của c để bảo đảm rằng chúng đều thuộc L_{k-1} .

Số lượng tập con độ dài $(k-1)$ của một tập gồm k phần tử là:

$$\binom{k}{k-1} = k$$

Tuy nhiên, do c được sinh ra bằng phép self-join từ hai itemset phổ biến thuộc L_{k-1} , nên chỉ cần kiểm tra các tập con còn lại của c (trừ 2 tập con tạo nên c).

Cụ thể, giả sử:

$$c = l_1 \cup l_2$$

với:

$$l_1 = \{i_1, \dots, i_{k-2}, i_{k-1}\}$$

$$l_2 = \{i_1, \dots, i_{k-2}, i_k\}$$

Hai tập con $c - \{i_{k-1}\} = l_2$ và $c - \{i_k\} = l_1$ đã chắc chắn phổ biến vì thuộc L_{k-1} .

Do đó chỉ cần kiểm tra các tập con còn lại, tức $k-2$ tập con.

Phiên bản cải tiến của thủ tục `has_infrequent_subset`:

Algorithm 2 Cải tiến has_infrequent_subset

Require: Candidate $c = \{i_1, i_2, \dots, i_k\}$, frequent itemsets L_{k-1}

Ensure: TRUE if c has an infrequent subset

```

1: for  $j = 1$  to  $k - 2$  do
2:    $s \leftarrow c - \{i_j\}$ 
3:   if  $s \notin L_{k-1}$  then
4:     return TRUE
5:   end if
6: end for
7: return FALSE

```

Câu 4.5

Section 4.2.2 describes a method for generating association rules from frequent itemsets. Propose a more efficient method. Explain why it is more efficient than the one proposed there. (Hint: consider incorporating the properties of Exercises 4.3(b), (c) into your design.)

Lời giải Sử dụng tính chất pruning của confidence:

- Nếu một luật $s \Rightarrow (l - s)$ không đạt *minconf*, thì mọi luật tạo từ các tập con của s cũng sẽ không đạt *minconf*.
- Vì vậy, ta không cần sinh toàn bộ các tập con của l .

Algorithm 3 Cải tiến thuật toán sinh luật kết hợp

Require: Tập phổ biến l , minimum confidence *minconf*

```

1: for all nonempty subsets  $s \subset l$  do
2:    $conf \leftarrow \frac{support(l)}{support(s)}$ 
3:   if  $conf \geq minconf$  then
4:     Output rule:


$s \Rightarrow (l - s)$


5:     Continue exploring subsets of  $s$ 
6:   else
7:     Prune all subsets of  $s$ 
8:   end if
9: end for

```

Phương pháp này hiệu quả hơn vì nó loại bỏ sớm các tập ứng viên không thể tạo ra luật mạnh. Nếu một luật không đạt *minconf*, mọi mở rộng của nó cũng không cần xét tiếp. Do đó, số lượng tập con cần sinh và kiểm tra giảm đáng kể so với cách brute-force sinh toàn bộ $2^{|I|} - 2$ tập con.

Câu 4.6

A database has five transactions. Let *min_sup* = 60% and *min_conf* = 80%.

TID	items_bought
T100	{M, O, N, K, E, Y}
T200	{D, O, N, K, E, Y}
T300	{M, A, K, E}
T400	{M, U, C, K, Y}
T500	{C, O, K, I, E}

- Find all frequent itemsets using Apriori and FP-growth, respectively. Compare the efficiency of the two mining processes.
- List all the strong association rules (with support *s* and confidence *c*) matching the following metarule, where *X* is a variable representing customers, and *item_i* denotes variables representing items:

$$\begin{aligned} \forall x \in \text{transaction}, \text{buys}(X, \text{item}_1) \wedge \text{buys}(X, \text{item}_2) \\ \Rightarrow \text{buys}(X, \text{item}_3) \quad [s, c] \end{aligned}$$

Lời giải a.

Vì có 5 transaction và *min_sup* = 60%, nên ngưỡng support tối thiểu là:

$$0.6 \times 5 = 3$$

Dùng Apriori

- Tập phổ biến 1-phần tử:

$$L_1 = \{E(4), K(5), M(3), O(3), Y(3)\}$$

- Candidate 2-itemset:

$$C_2 = \{EK, EM, EO, EY, KM, KO, KY, MO, MY, OY\}$$

- Tập phổ biến 2-phần tử:

$$L_2 = \{EK(4), EO(3), KM(3), KO(3), KY(3)\}$$

- Candidate 3-itemset sau bước prune:

$$C_3 = \{EKO\}$$

- Tập phổ biến 3-phần tử:

$$L_3 = \{EKO(3)\}$$

Do không sinh thêm được ứng viên độ dài 4, tập mục phổ biến cuối cùng là:

$$\{E, K, M, O, Y, EK, EO, KM, KO, KY, EKO\}$$


Dùng FP-growth

Các item phổ biến theo support giảm dần là:

$$K(5), E(4), M(3), O(3), Y(3)$$

Sắp xếp lại các item trong từng giao dịch theo thứ tự trên, ta được:

TID	Itemset đã được sắp xếp
T100	{K,E,M,O,Y}
T200	{K,E,O,Y}
T300	{K,E,M}
T400	{K,M,Y}
T500	{K,E,O}



Hình 1: Cây FP được xây dựng từ các giao dịch đã sắp xếp

Từ FP-tree, ta thu được các conditional pattern base chính:

- Với Y : sinh được mẫu phổ biến $KY(3)$.
- Với O : sinh được các mẫu phổ biến $EO(3)$, $KO(3)$, $EKO(3)$.
- Với M : sinh được mẫu phổ biến $KM(3)$.
- Với E : sinh được mẫu phổ biến $EK(4)$.

Do đó FP-growth cũng thu được đúng tập mục phổ biến:

$$\{E, K, M, O, Y, EK, EO, KM, KO, KY, EKO\}$$

So sánh: Apriori phải sinh candidate và quét CSDL nhiều lần, còn FP-growth khai thác trực tiếp trên FP-tree nên thường hiệu quả hơn.

b.

Mẫu luật yêu cầu về trái gồm 2 item và về phải gồm 1 item, nên chỉ cần xét tập phổ biến 3-phần tử:

$$EKO \text{ với support } \frac{3}{5} = 60\%$$

Các luật mạnh là:

$$\{K, O\} \Rightarrow \{E\} \quad [s = 60\%, c = \frac{\sup(EKO)}{\sup(KO)} = \frac{3}{3} = 100\%]$$

$$\{E, O\} \Rightarrow \{K\} \quad [s = 60\%, c = \frac{\sup(EKO)}{\sup(EK)} = \frac{3}{3} = 100\%]$$

$$\{E, K\} \Rightarrow \{O\}$$

không mạnh vì:

$$c = \frac{\sup(EKO)}{\sup(EK)} = \frac{3}{4} = 75\% < 80\%$$

Câu 4.8

A database has four transactions. Let **min_sup** = 60% and **min_conf** = 80%.

cust_ID	TID	items_bought (in the form of brand-item_category)
01	T100	{King's-Crab, Sunset-Milk, Dairyland-Cheese, Best-Bread}
02	T200	{Best-Cheese, Dairyland-Milk, Goldenfarm-Apple, Tasty-Pie, Wonder-Bread}
01	T300	{Westcoast-Apple, Dairyland-Milk, Wonder-Bread, Tasty-Pie}
03	T400	{Wonder-Bread, Sunset-Milk, Dairyland-Cheese}

- a. At the granularity of item_category (e.g., $item_i$ could be “Milk”), for the rule template,

$$\begin{aligned} \forall X \in transaction, buys(X, item_1) \wedge buys(X, item_2) \\ \Rightarrow buys(X, item_3) \quad [s, c], \end{aligned}$$

list the frequent k -itemset for the largest k , and all the strong association rules (with their support s and confidence c) containing the frequent k -itemset for the largest k .

- b. At the granularity of brand-item_category (e.g., $item_i$ could be “Sunset-Milk”), for the rule

template,

$$\forall X \in customer, buys(X, item_1) \wedge buys(X, item_2) \Rightarrow buys(X, item_3),$$

list the frequent k -itemset for the largest k (but do not print any rules).

Lời giải a.

Ở mức *item_category*, bỏ phần brand:

- $T100 = \{\text{Crab, Milk, Cheese, Bread}\}$
- $T200 = \{\text{Cheese, Milk, Apple, Pie, Bread}\}$
- $T300 = \{\text{Apple, Milk, Bread, Pie}\}$
- $T400 = \{\text{Bread, Milk, Cheese}\}$

Vì $\text{min_sup} = 60\%$ và có 4 transaction, nên ngưỡng support tối thiểu là:

$$0.6 \times 4 = 2.4 \Rightarrow 3$$

Các tập phổ biến lớn nhất có độ dài $k = 3$ và chỉ có một tập phổ biến 3-phần tử:

$$\{\text{Bread, Milk, Cheese}\}$$

với support:

$$\frac{3}{4} = 75\%$$

Các luật kết hợp mạnh chứa tập phổ biến 3-phần tử này là:

$$\text{Bread} \wedge \text{Cheese} \Rightarrow \text{Milk} \quad [s = 75\%, c = \frac{3}{3} = 100\%]$$

$$\text{Cheese} \wedge \text{Milk} \Rightarrow \text{Bread} \quad [s = 75\%, c = \frac{3}{3} = 100\%]$$

Các luật còn lại không mạnh vì:

$$\frac{3}{4} = 75\% < 80\%$$

b.

Ở mức *brand-item_category* với $X \in customer$, gộp toàn bộ giao dịch của cùng một khách hàng:

- Customer 01: {King's-Crab, Sunset-Milk, Dairyland-Cheese, Best-Bread, Westcoast-Apple, Dairyland-Milk, Wonder-Bread, Tasty-Pie}
- Customer 02: {Best-Cheese, Dairyland-Milk, Goldenfarm-Apple, Tasty-Pie, Wonder-Bread}
- Customer 03: {Wonder-Bread, Sunset-Milk, Dairyland-Cheese}

Vì có 3 customer nên ngưỡng support tối thiểu là:

$$0.6 \times 3 = 1.8 \Rightarrow 2$$

Các tập phổ biến lớn nhất có độ dài $k = 3$:

{Wonder-Bread, Dairyland-Milk, Tasty-Pie}

{Wonder-Bread, Sunset-Milk, Dairyland-Cheese}

Câu 4.9

Suppose that a large store has a transactional database that is distributed among four locations. Transactions in each component database have the same format, namely $T_j : \{i_1, \dots, i_m\}$, where T_j is a transaction identifier, and i_k ($1 \leq k \leq m$) is the identifier of an item purchased in the transaction. Propose an efficient algorithm to mine global association rules. Your algorithm should not require shipping all the data to one site and should not cause excessive network communication overhead.

Lời giải Một thuật toán hiệu quả để khai thác luật kết hợp toàn cục là:

1. Tại mỗi địa điểm, khai thác các tập mục phổ biến cục bộ với cùng ngưỡng *minsup*. Gọi CF là hợp của tất cả các tập mục phổ biến cục bộ:

$$CF = \bigcup_{i=1}^4 L_i$$

2. Gửi danh sách CF đến từng địa điểm. Mỗi địa điểm chỉ cần tính support cục bộ của các itemset trong CF , thay vì gửi toàn bộ transaction.
3. Cộng các support cục bộ của từng itemset trong CF để thu được support toàn cục.
4. Giữ lại các itemset có support toàn cục đạt ngưỡng $minsup$; đó là các tập mục phổ biến toàn cục.
5. Từ các tập mục phổ biến toàn cục, sinh các luật kết hợp mạnh theo ngưỡng $minconf$.

Ưu điểm: không cần gom toàn bộ dữ liệu về một nơi, chỉ trao đổi CF và support count, và không bỏ sót tập mục phổ biến toàn cục.

Câu 4.10

Suppose that frequent itemsets are saved for a large transactional database, DB . Discuss how to efficiently mine the (global) association rules under the same minimum support threshold, if a set of new transactions, denoted as ΔDB , is (incrementally) added in.

Lời giải Xem DB và ΔDB là hai partition của CSDL cập nhật:

- Với các itemset đã phổ biến trong DB , chỉ cần quét ΔDB một lần để cộng thêm support, rồi kiểm tra xem chúng còn phổ biến trong $DB \cup \Delta DB$ hay không.
- Với các itemset phổ biến trong ΔDB nhưng chưa phổ biến trong DB , quét DB một lần để lấy thêm support của chúng, rồi kiểm tra lại trên $DB \cup \Delta DB$.

Sau đó sinh các luật kết hợp mạnh từ tập mục phổ biến mới. Cách này tránh khai thác lại từ đầu.

Câu 4.11

Most frequent pattern mining algorithms consider only distinct items in a transaction. However, multiple occurrences of an item in the same shopping basket, such as four cakes and three jugs of milk, can be important in transactional data analysis. How can one mine frequent itemsets efficiently considering multiple occurrences of items? Propose modifications to the well-known algorithms, such as Apriori and FP-growth, to adapt to such a situation.

Lời giải Để xét nhiều lần xuất hiện của cùng một item, ta biểu diễn item kèm số lượng, chẳng hạn $(A:1)$, $(A:2)$, $(A:3)$, trong đó $(A:q)$ nghĩa là transaction chứa ít nhất q bản sao của A .

Sửa đổi Apriori

- Ở bước sinh L_1 , mỗi cặp $(i:q)$ được xem như một item riêng, và support của nó là số transaction có chứa ít nhất q bản sao của i .
- Khi sinh candidate k -itemset, vẫn dùng join và prune như Apriori, nhưng kiểm tra theo số lượng.
- Một transaction T hỗ trợ itemset định lượng X nếu:

$$\forall (i:q) \in X, \text{count}_T(i) \geq q$$

- Sau đó tiếp tục sinh $L_2, L_3, \dots$ như Apriori chuẩn.

Ví dụ, transaction chứa 4 cakes và 3 jugs of milk sẽ hỗ trợ $(cake:1), \dots, (cake:4)$ và $(milk:1), \dots, (milk:3)$.

Sửa đổi FP-growth

- Khi xây dựng FP-tree, mỗi item cũng được thay bằng dạng định lượng $(i:q)$.
- Mỗi transaction được chuyển thành tập các item định lượng mà nó hỗ trợ, sau đó sắp theo thứ tự support giảm dần để chèn vào cây.
- Quá trình khai thác conditional pattern base và conditional FP-tree vẫn giữ nguyên ý tưởng của FP-growth, nhưng phải bảo toàn thông tin về số lượng của từng item.

Tóm lại, cả Apriori và FP-growth đều có thể mở rộng bằng cách thay mô hình nhị phân bằng mô hình *item kèm số lượng*.

Câu 4.13

Give a short example to show that items in a strong association rule actually may be negatively correlated.

Lời giải Xét bảng đếm sau:

	B	$\overline{B}$	Σ_{row}
A	65	40	105
$\overline{A}$	35	10	45
Σ_{col}	100	50	150

Giả sử:

$$minsup = 40\%, \quad minconf = 60\%$$

Xét luật:

$$A \Rightarrow B$$

Ta có:

$$\text{support}(A \Rightarrow B) = \frac{65}{150} = 43.3\%$$

$$\text{confidence}(A \Rightarrow B) = \frac{65}{105} \approx 61.9\%$$

Vì support và confidence đều vượt ngưỡng, nên đây là một **luật kết hợp mạnh**.

Nhưng nếu xét:

$$\text{corr}(A, B) = \frac{P(A \cap B)}{P(A)P(B)}$$

thì:

$$P(A \cap B) = \frac{65}{150}, \quad P(A) = \frac{105}{150} = 0.7, \quad P(B) = \frac{100}{150} \approx 0.667$$

$$\text{corr}(A, B) = \frac{0.433}{0.7 \times 0.667} \approx 0.928 < 1$$

Do đó, dù $A \Rightarrow B$ là luật mạnh, A và B vẫn **tương quan âm**.

Câu 4.14

The following contingency table summarizes supermarket transaction data, where *hot dogs* refers to the transactions containing hot dogs, $\overline{\text{hot dogs}}$ refers to the transactions that do not contain hot dogs, *hamburgers* refers to the transactions containing hamburgers, and $\overline{\text{hamburgers}}$ refers to the transactions that do not contain hamburgers.

	<i>hot dogs</i>	$\overline{hot\ dogs}$	Σ_{row}
hamburgers	2000	500	2500
$\overline{hamburgers}$	1000	1500	2500
Σ_{col}	3000	2000	5000

- Suppose that the association rule “*hot dogs* $\Rightarrow$ *hamburgers*” is mined. Given a minimum support threshold of 25% and a minimum confidence threshold of 50%, is this association rule strong?
- Based on the given data, is the purchase of hot dogs independent of the purchase of hamburgers? If not, what kind of correlation relationship exists between the two?
- Compare the use of the all_confidence, max_confidence, Kulczynski, and cosine measures with lift and correlation on the given data.

Lời giải a.

Xét luật:

$$hot\ dogs \Rightarrow hamburgers$$

ta có:

$$\text{support} = \frac{2000}{5000} = 40\%$$

$$\text{confidence} = \frac{2000}{3000} = 66.7\%$$

Vì:

$$40\% \geq 25\%, \quad 66.7\% \geq 50\%$$

nên đây là một **luật kết hợp mạnh**.

b.

Nếu hai mặt hàng độc lập thì phải có:

$$P(hot\ dogs \cap hamburgers) = P(hot\ dogs) P(hamburgers)$$

Trong dữ liệu đã cho:

$$\begin{aligned}P(hot\ dogs) &= \frac{3000}{5000} = 0.6, \\P(hamburgers) &= \frac{2500}{5000} = 0.5, \\P(hot\ dogs \cap hamburgers) &= \frac{2000}{5000} = 0.4\end{aligned}$$

Do đó:

$$\frac{P(hot\ dogs \cap hamburgers)}{P(hot\ dogs)P(hamburgers)} = \frac{0.4}{0.6 \times 0.5} = 1.333 > 1$$

Vì vậy, hai mặt hàng **không độc lập** và có **tương quan dương**.

c.

Ta có:

$$\begin{aligned}\text{conf}(hot\ dogs \Rightarrow hamburgers) &= \frac{2000}{3000} = \frac{2}{3} \approx 0.667 \\ \text{conf}(hamburgers \Rightarrow hot\ dogs) &= \frac{2000}{2500} = 0.8\end{aligned}$$

Suy ra các độ đo:

$$\begin{aligned}all_confidence &= \min\left(\frac{2}{3}, 0.8\right) = \frac{2}{3} \approx 0.667 \\ max_confidence &= \max\left(\frac{2}{3}, 0.8\right) = 0.8 \\ Kulc &= \frac{1}{2} \left(\frac{2}{3} + 0.8\right) = \frac{11}{15} \approx 0.733 \\ cosine &= \frac{P(hot\ dogs \cap hamburgers)}{\sqrt{P(hot\ dogs)P(hamburgers)}} = \frac{0.4}{\sqrt{0.6 \times 0.5}} \approx 0.730 \\ lift &= \frac{0.4}{0.6 \times 0.5} = 1.333\end{aligned}$$

Dùng hệ số tương quan ϕ cho bảng 2×2 :

$$\phi = \frac{2000 \times 1500 - 500 \times 1000}{\sqrt{2500 \times 2500 \times 3000 \times 2000}} \approx 0.408$$

Tất cả các độ đo đều cho thấy quan hệ dương. Trong đó, $all_confidence$ là chặt nhất, $max_confidence$ là lớn nhất, còn $Kulc$ và $cosine$ cân bằng hơn vì xét cả hai hướng.